Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра ИУ5 «Системы обработки информации и управления»

Курс «Технологии машинного обучения»

Отчет по лабораторной работе №3 «Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей.

Выполнил:
студент группы ИУ5-64Б
Низовцев Р.А.

Проверил:
преподаватель каф. ИУ5
Гапанюк Ю.Е.

Москва, 2022 г.

Описание задания:

1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
2. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
3. Обучите модель ближайших соседей для произвольно заданного гиперпараметра K. Оцените качество модели с помощью подходящих для задачи метрик.
4. Произведите подбор гиперпараметра K с использованием GridSearchCV и/или RandomizedSearchCV и кросс-валидации, оцените качество оптимальной модели. Желательно использование нескольких стратегий кросс-валидации.
5. Сравните метрики качества исходной и оптимальной моделей.

Лабораторная работа №3: Подготовка обучающей и тестовой выборки, кроссвалидация и подбор гиперпараметров на примере метода ближайших соседей.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split, GridSearchCV,
RandomizedSearchCV from sklearn.neighbors import KNeighborsRegressor from
sklearn.preprocessing import MinMaxScaler, StandardScaler from matplotlib import
pyplot as plt import seaborn as sns
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
from warnings import simplefilter


simplefilter('ignore')
```

Подключение библиотек

In [1]:

Загрузка предобработанного в первой лабе датасета

In [2]:
```
data = pd.read_csv('laptop_price_preprocessed.csv')
```

In [3]:

Out[3]:

```
data.head()
```

	laptop_ID	Company	Product	TypeName	Inches	Ram_GB	OpSys	Weight_kg	Price_euros	ScreenType	...	ScreenRes	Cpu_type	Cpu_GHz	Gpu_producer	Gpu_model	Memory
0	1	Apple	MacBook Pro	Ultrabook	13.3	8	macOS	1.37	1339.69	IPS Panel Retina Display	...	2560x1600	Intel Core i5	2.3	Intel	Iris Plus Graphics 640	128GB SSD
1	2	Apple	Macbook Air	Ultrabook	13.3	8	macOS	1.34	898.94	-	...	1440x900	Intel Core i5	1.8	Intel	HD Graphics 6000	128GB SSD
2	3	HP	250 G6	Notebook	15.6	8	No OS	1.86	575.00	Full HD	...	1920x1080	Intel Core i5 7200U	2.5	Intel	HD Graphics 620	256GB SSD
3	4	Apple	MacBook Pro	Ultrabook	15.4	16	macOS	1.83	2537.45	IPS Panel Retina Display	...	2880x1800	Intel Core i7	2.7	AMD	Radeon Pro 455	512GB SSD
4	5	Apple	MacBook Pro	Ultrabook	13.3	8	macOS	1.37	1803.60	IPS Panel Retina Display	...	2560x1600	Intel Core i5	3.1	Intel	Iris Plus Graphics 650	128GB SSD

5 rows × 22 columns

In [4]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1250 entries, 0 to 1249
Data columns (total 22 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
0   laptop_ID     1250 non-null   int64
1   Company       1250 non-null   object
2   Product       1250 non-null   object
3   TypeName      1250 non-null   object
4   Inches        1250 non-null   float64
5   Ram_GB        1250 non-null   int64
6   OpSys         1250 non-null   object
7   Weight_kg     1250 non-null   float64
8   Price_euros   1250 non-null   float64
```

```
9   ScreenType    1250 non-null   object
10  ScreenWidth   1250 non-null   int64
11  ScreenHeight  1250 non-null   int64
12  ScreenRes     1250 non-null   object
13  Cpu_type      1250 non-null   object
14  Cpu_GHz       1250 non-null   float64
15  Gpu_producer  1250 non-null   object
16  Gpu_model     1250 non-null   object
17  Memory1_GB    1250 non-null   int64
18  Memory1_type  1250 non-null   object
19  Memory2_GB    1250 non-null   int64
20  Memory2_type  1250 non-null   object   21  Memory2       1250 non-null   object  dtypes: float64(4), int64(6), object(12) memory usage: 215.0+
    KB
```

```
category_cols = ['Memory1_type', 'Memory2_type', 'Company', 'Product', 'TypeName', 'OpSys',
                 'ScreenType', 'Cpu_type', 'Gpu_producer', 'Gpu_model']


print('Количество уникальных значений\n')
for col in category_cols:
    print(f'{col}: {data[col].unique().size}')
```

Кодирование категориальных признаков

In [5]:

```
Количество уникальных значений

Memory1_type: 4
Memory2_type: 4
Company: 19
Product: 618
TypeName: 6
OpSys: 9
ScreenType: 21
Cpu_type: 93
Gpu_producer: 4
Gpu_model: 110
```

In [6]: `remove_cols = ['Product']` In

[7]:

```
    category_cols.remove(col)
data = pd.get_dummies(data, columns=category_cols)
```

for col

in

```
data.drop(remove_cols, axis=1, inplace=True)
data.drop(['laptop_ID', 'ScreenRes', 'Memory2'], axis=1, inplace=True)
data.describe()
```

	Inches	Ram_GB	Weight_kg	Price_euros	ScreenWidth	ScreenHeight	Cpu_GHz	Memory1_GB	Memory2_GB	Memory1_type_Flash Storage	...	Gpu_model_Radeon R7 M440

remove_cols:

In [8]: Out[8]:

Gpu_m
count
1250.0 00000
1250.0 00000
1250.0 00000
1250.0 00000
1250.0 00000
1250.0 00000
1250.0 00000
1250.0 00000
1250.0 00000
1250.0 00000

1250.000000

...

1250.000000

mean

15.034880

8.443200

2.046152

1132.177480

1897.272000

1072.256000

2.303856

447.180800

174.675200

0.055200

...

0.002400

std

1.416838

5.121929

0.669436

703.965444

491.854703

283.172078

0.502772

367.670259

411.340426

0.228462

...

0.048951

min

10.100000

2.000000

0.690000

174.000000

1366.000000

768.00

0000

0.900000

8.000000

0.000000

0.000000

...

0.000000

25%

14.000000

4.000000

1.500000

600.425000

1600.000000

900.000000

2.000000

256.000000

0.000000

0.000000

...

0.000000

50%

15.600000

8.000000

2.040000

985.000000

1920.000000

1080.000000

2.500000

256.000000

0.000000

0.000000

...

0.000000

75%

15.600000

8.000000

2.310000

1489.747500

1920.000000

1080.000000

2.700000

512.000000

0.000000

0.000000

...

0.000000

max

18.400000

64.000000

4.700000

6099.000000

3840.000000

2160.000000

3.600000

2048.000000

2048.000000

1.000000

...

1.000000

8 rows × 279 columns

```
y = data['Price_euros']
X = data.drop('Price_euros', axis=1)
x_train, x_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=3)
```

Разделение выборки на обучающую и тестовую

In [9]:

```
scaler = MinMaxScaler().fit(x_train)
x_train = pd.DataFrame(scaler.transform(x_train), columns=x_train.columns)
x_test = pd.DataFrame(scaler.transform(x_test), columns=x_train.columns)
x_train.describe()
```

Масштабирование данных

In [10]:

Out[10]:

	Inches	Ram_GB	Weight_kg	ScreenWidth	ScreenHeight	Cpu_GHz	Memory1_GB	Memory2_GB	Memory1_type_Flash Storage	Memory1_type_HDD	...	Gpu_model_Radeon R7 M440	Gp

count	875.000000	875.000000	875.000000	875.000000	875.000000	875.000000	875.000000	875.000000	875.000000	875.000000	...	875.000000
mean	0.590967	0.103300	0.337162	0.214886	0.218279	0.518493	0.214407	0.084987	0.056000	0.296000	...	0.002286
std	0.173292	0.085202	0.164937	0.203257	0.207356	0.188520	0.180521	0.199047	0.230053	0.456752	...	0.047782
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	...	0.000000
25%	0.469880	0.032258	0.201995	0.094584	0.094828	0.407407	0.118110	0.000000	0.000000	0.000000	...	0.000000
50%	0.662651	0.096774	0.336658	0.223929	0.224138	0.592593	0.118110	0.000000	0.000000	0.000000	...	0.000000
75%	0.662651	0.096774	0.401496	0.223929	0.224138	0.666667	0.244094	0.000000	0.000000	1.000000	...	0.000000
max	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	...	1.000000

8 rows × 278 columns

```
def print_metrics(y_test, y_pred):
    print(f"R^2: {r2_score(y_test, y_pred)}")
print(f"MSE: {mean_squared_error(y_test, y_pred)}")
print(f"MAE: {mean_absolute_error(y_test, y_pred)}")
     def print_cv_result(cv_model, x_test,
y_test):
    print(f'Оптимизация метрики {cv_model.scoring}:
{cv_model.best_score_}')     print(f'Лучший параметр:
{cv_model.best_params_}')     print('Метрики на тестовом наборе')
print_metrics(y_test, cv_model.predict(x_test))     print()
```

Обучение KNN с произвольным k

In [11]:

In [12]:
```
base_k = 7 base_knn =
 KNeighborsRegressor(n_neighbors=base_k)
 base_knn.fit(x_train, y_train) y_pred_base =
 base_knn.predict(x_test) print(f'Test metrics
 for KNN with k={base_k}\n')
 print_metrics(y_test, y_pred_base)
```

```
Test metrics for KNN with k=7

R^2: 0.7722710180524757
MSE:     98607.68197025849
MAE: 218.48083428571428
```

```
metrics = ['r2', 'neg_mean_squared_error', 'neg_mean_absolute_error']
cv_values = [5, 10]
 for cv in
cv_values:
    print(f'Результаты кросс-валидации при cv={cv}\n')
for metric in metrics:
        params = {'n_neighbors': range(1, 30)}
        knn_cv = GridSearchCV(KNeighborsRegressor(), params, cv=cv, scoring=metric, n_jobs=-1)
knn_cv.fit(x_train, y_train)
        print_cv_result(knn_cv, x_test, y_test)
```

Кросс-валидация

In [13]:

```
Результаты кросс-валидации при cv=5

Оптимизация метрики r2: 0.7726372857710311
Лучший параметр: {'n_neighbors': 4}
Метрики на тестовом наборе
R^2: 0.7841876602937758
MSE: 93447.72183591667
MAE: 209.1155

Оптимизация метрики neg_mean_squared_error: -116355.60149814286
Лучший параметр: {'n_neighbors': 4}
Метрики на тестовом наборе
R^2: 0.7841876602937758
MSE: 93447.72183591667
MAE: 209.1155

Оптимизация метрики neg_mean_absolute_error: -223.9260514285714
Лучший параметр: {'n_neighbors': 4}
Метрики на тестовом наборе
R^2: 0.7841876602937758
MSE: 93447.72183591667
MAE: 209.1155

Результаты кросс-валидации при cv=10
```

```
Оптимизация метрики r2: 0.7792314885077024
Лучший параметр: {'n_neighbors': 4}
Метрики на тестовом наборе
R^2: 0.7841876602937758
MSE: 93447.72183591667
MAE: 209.1155

Оптимизация метрики neg_mean_squared_error: -112797.48419457053
Лучший параметр: {'n_neighbors': 4}
Метрики на тестовом наборе
R^2: 0.7841876602937758
MSE: 93447.72183591667
MAE: 209.1155

Оптимизация метрики neg_mean_absolute_error: -217.6273088100836
Лучший параметр: {'n_neighbors': 4}
Метрики на тестовом наборе
R^2: 0.7841876602937758
MSE: 93447.72183591667
MAE: 209.1155
```

In [14]:
```
best_k = 4 y_pred_best = KNeighborsRegressor(n_neighbors=best_k).fit(x_train,
 y_train).predict(x_test)
```

```
print('Basic model\n')
print_metrics(y_test, y_pred_base)
print('_____________________')
print('\nOptimal model\n')
print_metrics(y_test, y_pred_best)
```

Сравнение исходной и оптимальной моделей

In [15]:

```
Basic model

R^2: 0.7722710180524757
MSE: 98607.68197025849
MAE: 218.48083428571428
_____________________

Optimal model

R^2: 0.7841876602937758
MSE:     93447.72183591667
MAE: 209.1155
```

```
res = pd.DataFrame({'y_test': y_test, 'y_pred_best': y_pred_best}).sort_values(by='y_test')
res.head()
```

Визуализация результатов оптимальной модели

In [16]:

Out[16]:

	y_test	y_pred_best
1191	174.0	292.0000
1098	196.0	267.2250
31	199.0	313.2475
1081	209.0	325.0000
1243	209.0	285.9500

```
plt.figure(figsize=(16, 5)) sns.scatterplot(range(res.shape[0]),
res['y_test'], label='actual')
sns.scatterplot(range(res.shape[0]), res['y_pred_best'], label='predicted',
alpha=0.6) plt.ylabel('price') plt.xlabel('') plt.title(f'Best KNN model results
(k={best_k})') plt.tick_params(axis='x', bottom=False, labelbottom=False)
plt.show()
```

In [17]:

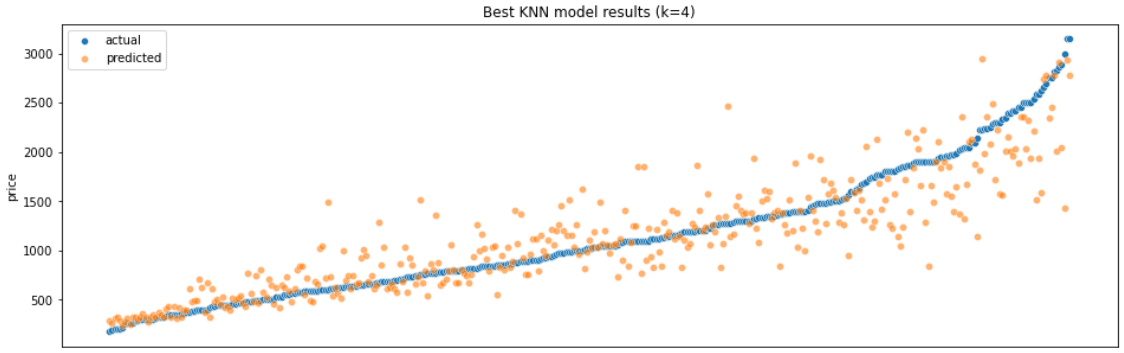
Best KNN model results (k=4)
actual
predicted
price
3000
2500
2000
1500
1000
500